

对偶

对偶理论 *primal dual*

有约束问题的无约束形式

对于有约束优化问题

$$\begin{aligned} \text{minimize} \quad & f_0(x) \\ \text{subject to} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

定义域

$$\mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$$

可转化为无约束优化问题,即

$$\text{minimize} \quad f_0(x) + \sum_{i=1}^m I_-(f_i(x)) + \sum_{i=1}^p I_0(h_i(x))$$

其中

$$I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u \geq 0 \end{cases}$$

$$I_0(u) = \begin{cases} 1 & u \in \{0\} \\ 0 & u \notin \{0\} \end{cases}$$

$I_0(u)$ 可看成是集合 $\{0\}$ 的示性函数, $I_-(u)$ 可看成是对原问题违反约束 $f_i(x)$ 的一种惩罚,一旦原问题违反约束,则 $f_i(x)$ 的值会大于0,则 $I_-(u) = \infty$, 整个无约束函数的最小值为 ∞ .

Lagrange 函数,自变量为 x, λ, v

Lagrange 函数的定义为:

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x), x \in R^n, \lambda \in R_+^m, v \in R^p$$

可以看出,有约束问题的无约束形式与 Lagrange 函数有些相似,我们可以认为, Lagrange 函数用线性的惩罚函数(或者惩罚力度比较弱的惩罚函数)代替了函数 $I_0(u)$, $I_-(u)$.

对于不等式约束,如果 $f_i(x) \geq 0$, 那么惩罚力度开始增加, 如果 $f_i(x) < 0$, 不但没有惩罚,反而会有奖励,即 $\text{minimize } L(x, \lambda, v)$ 会取到更小的值.

对于等式约束,待补充.

用线性函数 $\lambda_i u_i$ 去逼近 $I_-(u)$ 是远远不够的,但是线性函数至少可以看成是示性函数的一个下估计,我们可以得到, 对偶函数是原问题最优函数值的一个下界.

Lagrange 对偶函数,自变量为 λ, v

Lagrange 对偶函数的定义为:

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) = \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right),$$

$\lambda \in R_+^m, v \in R^p, \mathcal{D}$ 是原问题的定义域

Lagrange 对偶函数相比于 Lagrange 函数,多出了对 $x(x \in \mathcal{D})$ 求最大下确界的过程,变量 x 被对偶函数所隐藏.

注意,这里 Lagrange 对偶函数和原问题的定义域是相同的,都为 \mathcal{D} , 这很关键.

证明 Lagrange 对偶函数构成了原问题最优值 p^* 的下界

对任意的 $\lambda \succeq 0$ 和 v , 下式成立: \preceq

$$g(\lambda, v) \leq p^*$$

证明:

设 \tilde{x} 是原问题在定义域 \mathcal{D} 中的一个可行点(不一定是最优解), 正是由于 $\tilde{x} \in \mathcal{D}$, 所以有 $f_i(\tilde{x}) \leq 0, h_i(\tilde{x}) = 0$, 根据假设 $\lambda \succeq 0$, 我们有

$$\begin{aligned} & \sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{i=1}^p v_i h_i(\tilde{x}) \\ &= \sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{i=1}^p v_i * 0 \\ &= \sum_{i=1}^m \lambda_i f_i(\tilde{x}) \leq 0 \end{aligned}$$

则

$$\begin{aligned} L(\tilde{x}, \lambda, v) &= f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{i=1}^p v_i h_i(\tilde{x}) \\ &= f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) \leq f_0(\tilde{x}) \end{aligned}$$

式 $\inf_{x \in \mathcal{D}} L(x, \lambda, v)$ 表明函数 $L(x, \lambda, v)$ 在集合 \mathcal{D} 中的下界, 因此有

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) \leq L(\tilde{x}, \lambda, v) \leq f_0(\tilde{x})$$

因此 Lagrange 对偶函数构成了原问题最优值 p^* 的下界.

证明 Lagrange 对偶函数为凹函数

无论原问题是否为凸问题, 无论 $f_0(x)$, $f_i(x)$, $h_i(x)$ 是什么类型的函数. 但 Lagrange 对偶函数是一个凹函数, 证明思路如下: 集合 \mathcal{D} 无论是否连续, 都可以看成是变量 x 的有限集合, 当对偶函数 $g(\lambda, v)$ 中的 λ, v 为定值时, 则对于集合 \mathcal{D} 中的每一个 x_i 都有 $f_i(x_i)$, $h_i(x_i)$ 与之对应,

令

$$\begin{aligned}\lambda &= [\lambda_1, \lambda_2, \dots, \lambda_m] \\ v &= [v_1, v_2, \dots, v_p] \\ F(x) &= [f_1(x), f_2(x), \dots, f_m(x)] \\ H(x) &= [h_1(x), h_2(x), \dots, h_p(x)] \\ \mathcal{D} &= \{x_0, x_1, \dots, x_n\}, \quad \text{当集合 } \mathcal{D} \text{ 为连续值集合时, } n \rightarrow \infty\end{aligned}$$

且

$$\begin{aligned}g(\lambda, v) &= \inf_{x \in \mathcal{D}} L(x, \lambda, v) \\ &= \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right) \\ &= \inf_{x \in \mathcal{D}} (f_0(x) + \lambda F(x)^T + v H(x)^T)\end{aligned}$$

则有

$$\begin{aligned}g(\lambda, v) &= \inf_{x \in \mathcal{D}} L(x, \lambda, v) \\ &= \inf \left[(f_0(x_0) + \lambda F(x_0)^T + v H(x_0)^T), \right. \\ &\quad (f_0(x_1) + \lambda F(x_1)^T + v H(x_1)^T), \\ &\quad \dots, \\ &\quad \left. (f_0(x_n) + \lambda F(x_n)^T + v H(x_n)^T) \right]\end{aligned}$$

为了方便书写和观察, 令

$$\begin{aligned}A_i &= f_0(x_i) \\ B_i &= F(x_i) \\ C_i &= H(x_i)\end{aligned}$$

则

$$\begin{aligned}
g(\lambda, v) &= \inf_{x \in \mathcal{D}} L(x, \lambda, v) \\
&= \inf \left[(f_0(x_0) + \lambda F(x_0)^T + v H(x_0)^T), \right. \\
&\quad (f_0(x_1) + \lambda F(x_1)^T + v H(x_1)^T), \\
&\quad \quad \quad \dots, \\
&\quad \left. (f_0(x_n) + \lambda F(x_n)^T + v H(x_n)^T) \right] \\
&= \inf \left[(A_0 + \lambda B_0^T + v C_0^T), \right. \\
&\quad (A_1 + \lambda B_1^T + v C_1^T), \\
&\quad \quad \quad \dots, \\
&\quad \left. (A_n + \lambda B_n^T + v C_n^T) \right]
\end{aligned}$$

易知 $A_i + \lambda B_i^T + v C_i^T$ 是关于变量 λ, v 的仿射函数 因为 **凹函数的逐点最大下确界仍是凹函数(仿射函数即是凹函数,也是凸函数)**, 因此 Lagrange 对偶函数仍是凹函数.

Lagrange 对偶问题

Lagrange 对偶问题的形式如下所示:

$$\text{maximize } g(\lambda, v)$$

$$\text{subject to } \lambda \succeq 0$$

Lagrange **对偶问题** 可以用来寻找 Lagrange **对偶函数** 的最大值.由前面的内容可知, Lagrange **对偶函数** 可以在 λ, v 确定的情况下,对 x ($x \in \mathcal{D}$) 求 Lagrange **函数** 的最大下确界(最小值),我们将 Lagrange 对偶问题写成如下形式:

$$\max_{\lambda \succeq 0} \inf_{x \in \mathcal{D}} L(x, \lambda, v)$$

或者如下形式(当 max 可以取到时)

$$\sup_{\lambda \succeq 0} \inf_{x \in \mathcal{D}} L(x, \lambda, v)$$

对 Lagrange 对偶的鞍点解释, 矮个子里挑高个子 和 高个子里挑矮个子

为了简化讨论,假设原问题没有等式约束

$$\text{minimize } f_0(x)$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

原问题的最优值 p^* 与下面这个问题的最优值等价:

构造原问题的 Lagrange 函数,即:

$$L(x, \lambda) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x)$$

求 Lagrange 函数在 x 确定的情况下, 对 $\lambda \succeq 0$ 求最小上确界:

$$\begin{aligned}\sup_{\lambda \succeq 0} L(x, \lambda) &= \sup_{\lambda \succeq 0} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \right) \\ &= \begin{cases} f_0(x) & f_i(x) \leq 0, i = 1, \dots, m \\ \infty & \text{otherwise} \end{cases}\end{aligned}$$

当 $f_i(x) > 0$ 时,只需要让相应的 $\lambda_i = +\infty$ 其余 $\lambda_j = 0$ ($i \neq j$),则 Lagrange 函数对 $\lambda \succeq 0$ 求最小上确界的结果为 $+\infty$, 此时无论 $f_0(x)$ 的值是多少都无意义, 在这里不考虑 $f_0(x_i) = \pm\infty$. 这种情况下, 我们将无法取得一个有效值, 因此讨论这种情况的最小上确界无意义.

求得 $\sup_{\lambda \succeq 0} L(x, \lambda)$ 的结果之后, 再求在 $x \in \mathcal{D}$ 的情况下对 $\sup_{\lambda \succeq 0} L(x, \lambda)$ 求最大下确界, 即

$\inf_{x \in \mathcal{D}} \sup_{\lambda \succeq 0} L(x, \lambda)$, 这等价于求解原问题. 令原问题的最优值为 p^* :

$$\begin{aligned}p^* &= \inf_{x \in \mathcal{D}} \sup_{\lambda \succeq 0} L(x, \lambda) \\ &= \inf_{x \in \mathcal{D}} \sup_{\lambda \succeq 0} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \right) \\ &= \inf_{x \in \mathcal{D}} \begin{cases} f_0(x) & f_i(x) \leq 0, i = 1, \dots, m \\ \infty & \text{otherwise} \end{cases} \\ &= \inf_{x \in \mathcal{D}} f_0(x) \quad \text{subject to} \quad f_i(x) \leq 0, i = 1, \dots, m \\ &= \min_{x \in \mathcal{D}} f_0(x) \quad \text{subject to} \quad f_i(x) \leq 0, i = 1, \dots, m \\ &\quad (\text{如果最小值可以取到, 则 } \sup \text{ 与 } \min \text{ 等价})\end{aligned}$$

设对偶问题的最优值为 d^* , 根据对偶问题的定义:

$$\begin{aligned}d^* &= \sup_{\lambda \succeq 0} g(\lambda, v) \\ &= \sup_{\lambda \succeq 0} \inf_{x \in \mathcal{D}} L(x, \lambda) \\ &= \sup_{\lambda \succeq 0} \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \right)\end{aligned}$$

因此**弱对偶性**可以表示为下述不等式

$$\begin{aligned}\text{对偶问题的最优值 } d^* &\leq \text{原问题的最优值 } p^* \\ d^* &\leq p^* \\ \sup_{\lambda \succeq 0} \inf_{x \in \mathcal{D}} L(x, \lambda) &\leq \inf_{x \in \mathcal{D}} \sup_{\lambda \succeq 0} L(x, \lambda)\end{aligned}$$

而**强对偶性**可以表示为下述等式

$$\begin{aligned}\text{对偶问题的最优值 } d^* &= \text{原问题的最优值 } p^* \\ d^* &= p^* \\ \sup_{\lambda \succeq 0} \inf_{x \in \mathcal{D}} L(x, \lambda) &= \inf_{x \in \mathcal{D}} \sup_{\lambda \succeq 0} L(x, \lambda)\end{aligned}$$

当 $p^* = d^*$ 时,**强对偶成立**, 强对偶性意味着对 x 求极小和对 $\lambda \succeq 0$ 求极大可以互换而不影响结果.

鞍点定义

我们称一对 $\tilde{w} \in W$ 是函数 f (以及 W 和 Z) 的鞍点, 如果对任意 $w \in W$ 和 $z \in Z$ 下式成立

$$f(\tilde{w}, z) \leq f(\tilde{w}, \tilde{z}) \leq f(w, \tilde{z}).$$

换言之, $g_1(w) = f(w, \tilde{z})$ 在 \tilde{w} 处取得最小值(关于变量 $w \in W$), $g_2(z) = f(\tilde{w}, z)$ 在 \tilde{z} 处取得最大值 (关于变量 $z \in Z$):

$$f(\tilde{w}, \tilde{z}) = \inf_{w \in W} f(w, \tilde{z}), \quad f(\tilde{w}, \tilde{z}) = \sup_{z \in Z} f(\tilde{w}, z)$$

上式意味着强极大极小性质成立, 且共同值为 $f(\tilde{w}, \tilde{z})$. 回到我们关于 Lagrange 对偶的讨论, 如果 x^* 和 λ^* 分别是原问题和对偶问题的最优点, 且强对偶性成立, 则它们是 Lagrange 函数的一个鞍点.

反过来同样成立: 如果 (x, λ) 是 Lagrange 函数的一个鞍点, 那么 x 是原问题的最优解, λ 是对偶问题的最优解, 且最优对偶间隙为零.

对偶的操作

在本文中, 我们可以看到对偶操作消去了一些变量, 用集合中显性的值来取代某一变量, 另外, 构造了许多的仿射函数, 最后, 进行取最大下界或最小上界操作. 我们应该学会这种变换思想

参考资料

- [1] [Convex Optimization – Boyd and Vandenberghe](#)
- [2] [中科大-凸优化](#)